ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas · Carrera de Ciencia de Datos e Inteligencia Artificial

INFORME DE LABORATORIO SEMANA · 3

Practica Muestra vs Población

Laboratorio complementario · Semana 3 Asignatura IDSD422 — Estadística y Programación para Ciencia de Datos I

Estudiante(s)	Fogacho Cuaspa Eduardo Mateo – Usuario de GitHub: edufgch0428
Docente	Christian Suárez
Período académico	2026-B
Fecha de entrega	23 de octubre del 2026
Repositorio (fork)	https://github.com/edufgch0428/IDSD422-lab-muestreo-poblacion

1. Introducción

La empresa RetailAndina S.A., a través de su departamento de Business Intelligence, necesita saber acerca de la base de fidelización, específicamente los tipos de variables que se maneja y que beneficio se puede sacar al momento de procesarlas, buscando un aprovechamiento de estas. Además, la gerencia requiere estimar el ingreso mensual promedio de sus clientes a partir de una muestra con 20 registros de una población de 400 registros. De esta manera, clasifiqué los distintos tipos de variables y realicé los diversos cálculos con los diseños de muestreo como aleatorio simple, estratificado y por conveniencia.

Para esta parte, es sumamente importante clasificar los distintos datos como corresponden para obtener resultados exactos y sin ambigüedades ya que al tener análisis erróneos puede desencadenar en diversos problemas como una toma de decisiones de manera errónea, perjudicando a la empresa. Por otro lado, una muestra mal diseñada no se corrige añadiendo más filas.

2. Objetivos

Objetivo General: Clasificar las variables de la base de fidelización de RetailAndina S.A. y calcular el ingreso mensual promedio de los clientes con tres técnicas de muestreo.

Objetivos específicos:

1. Clasificar las distintas variables que existen en el archivo clientes.csv de acuerdo con su continuidad y su orden con su verificación a través del código.
2. Calcular los ingresos mensuales promedio de los 400 clientes de clientes_400.csv y de 20 clientes a través de técnicas de muestreo como aleatorio simple, estratificado y por conveniencia.
3. Contrastar la media de cada muestra con su parámetro poblacional e interpretar su respectivo sesgo.

3. Desarrollo de la práctica.

3.1 Parte A · Clasificación de las variables

Para este apartado, ejecuté el archivo denominado clasificación_variables.py, en el cual se encontraba el script de la práctica. Esto hice con ayuda del lenguaje de programación Python y el editor de código denominado Visual Studio Code, así obtuve como resultado lo que se indica en la Figura 1. A su vez, a través de código, mostré cuántas categorías hay y cuales son, el orden de las variables ordinales como nivel_educacion y satisfacción que se muestran en las Figuras 2, 3 y 4 respectivamente (pandas development team, 2026a).

Variable	Tipo	Justificación (criterio)	Verificación en código
Cliente_id	Categórica nominal	Es una etiqueta que se le da al cliente.	str, 12 únicos.
edad	Numérica discreta	En este caso, se manejan datos enteros para reflejar la edad de cada cliente, pues, tener	int64, 12 únicos.

		una edad en fracción no resulta coherente.	
Numero_hijos	Numérica discreta	El número de hijos es reflejado a través de números enteros para que tenga concordancia, pues, tener un número de hijos en fracción no presenta una coherencia.	int64, 5 únicos en una escala del 0 al 4.
Genero	Categórica nominal	Se da una etiqueta a cada género de cada cliente.	str, 3 únicos.
Nivel_educacion	Categórica ordinal	En este caso, el orden de las etiquetas si importa porque existe un orden natural.	str, 4 únicos. Fue comprobado mediante las funciones min() y max().
Ciudad	Categórica nominal.	Solamente se dan etiquetas a las diversas ciudades sin importar el orden.	str, 3 únicos.
Ingresos_mensuales	Numérica continua	Es continua porque los ingresos de cada cliente se encuentran entre un gran rango de números y no solamente se maneja enteros, ya que se puede manejar en fracciones.	int64, 12 únicos.
Satisfaccion	Categórica ordinal	Se debe porque se trabaja con etiquetas que reflejan la satisfacción de cada cliente que llegan como entero.	int64, 4 únicos. Fue comprobado mediante las funciones min() y max().

¿Qué te dijo el dtype de satisfaccion y por qué no basta para clasificarla? ¿Qué pasa si una ordinal queda como texto sin declarar el orden?

El dtype de satisfacción, con ayuda del script que ejecuté, indica que es un int64, dicho de esta manera, solamente el número no basta para clasificarla porque no se le da un significado o no se le categoriza de acuerdo con la Figura 1.

En este caso, se ordenará de manera alfabética al quedar como texto sin declarar el orden tal y como en la Figura 2.

3.2 Parte B · Población vs. Muestra

En este caso, codifiqué código para complementar lo que se tenía en el archivo muestreo.py, de esta manera conseguí obtener los diferentes resultados útiles para el desarrollo en esta práctica con el lenguaje de programación Python como se muestran en las Figuras 5, 6 y 7; donde se encuentra la información de toda la población, como se aplica los métodos de muestreo y el cálculo de la media estimada en conjunto con el parámetro poblacional respectivamente (pandas development team, 2026b).

Concepto	**Valor**
Población (N)	400
Variable de interés	Ingreso medio
Parámetro poblacional (media)	1330.72
¿Por qué se muestrea si aquí el parámetro existe y se calculó?	Porque es difícil procesar todos los datos exactos de todos los clientes a la vez. Dicho de esta manera, realicé los cálculos con los diferentes métodos específicos de muestreo para reflejar que en efecto el uso de estos es confiable.

Diseño	**n**	**Media estimada**	**Composición por ciudad**	**Diferencia vs parámetro**
Por conveniencia (head)	20	1348.50	Quito: 20	+17.78
Aleatorio simple (sample)	20	1336.00	Cuenca: 8, Quito: 8, Guayaquil: 4	+5.28
Estratificado (groupby + 5%)	20	1287.50	Quito: 10, Guayaquil: 6, Cuenca: 4	-43.22

Semilla	**1**	**2**	**3**	**4**	**5**
Media	1336.00	1405.00	1235.00	1491.50	1288.00

P2. ¿Cuánto vale el parámetro poblacional y cuánto estimó cada diseño? ¿Cuál quedó más cerca y por qué eso no alcanza para declarar un ganador?

El parámetro poblacional de todos los cuatrocientos clientes dicta un total de 1330.72 y a su vez, en el método por conveniencia reflejó una media estimada 1348.50, mientras que, en el aleatorio simple reflejó una media estimada de 1336.0 y finalmente, el estratificado dictó una media de 1287.50.

El método que quedó más cerca a diferencia de los demás fue aleatorio simple, pero esto no es suficiente porque la media estimada respectiva provino de un solo sorteo con la semilla 1. Si se hace otro sorteo al cambiar la semilla, se obtendrá resultados distintos.

P3. La muestra por conveniencia también tiene 20 filas. ¿Qué defecto tiene y cómo lo delatas en la composición por ciudad? ¿Se corrige tomando más filas?

El defecto que tiene es que solamente toma los datos o muestras de clientes de Quito, cuando en los datos se tiene clientes también en Guayaquil y Cuenca de acuerdo con la Figura 2. Esto no se puede corregir al aumentar más filas porque de esta manera, se va a tomar más muestras de lo establecido a diferencia de los demás métodos que solamente ocupan veinte muestras eliminando esa igualdad.

P4. El sorteo aleatorio dio un número distinto en cada semilla. ¿Qué implica esa variabilidad para una empresa que va a decidir con un solo estudio?

Esa variabilidad implica que no existe una homogeneidad clara en cuanto a los datos de los ingresos mensuales de cada cliente ya que de acuerdo con los diferentes datos que obtuve al tomar una semilla de diferente valor, obtuve medias muy distintas y que no se acercaban al parámetro poblacional. Por lo tanto, tomar una decisión solamente basándose en un solo estudio, resultaría erróneo por la variabilidad descrita anteriormente.

P5. ¿Cuándo usarías cada diseño en la práctica? Relaciona cada uno con un uso real (piloto, subgrupos que deben aparecer, conclusión sobre toda la población).

- Por conveniencia: Lo usaría para realizar pruebas rápidas o pruebas piloto en algún experimento donde requiera una toma de datos para validar que el sistema de recolección implementado es el idóneo. Todo esto debido a los altos sesgos que pueden existir al momento de su implementación.
- Aleatorio simple: Para este caso, lo usaría para obtener alguna conclusión/conclusiones acerca de toda una población ya que se puede abarcar mucha más información debido a que, en este método, todos tienen la misma probabilidad de ser seleccionados.
- Estratificado: La mejor opción es usarlo para abarcar todos los subgrupos que puedan existir en una población, de esta manera, ningún elemento queda excluido del muestreo y así, obtendríamos datos más reales al aplicar algún cálculo.

4. ¿Qué aprendí en esta práctica?

En esta práctica aprendí a cómo aplicar los distintos métodos de muestreo en diversos datos a través del lenguaje de programación denominado Python y gracias a ello, tuve resultados de manera instantánea. Entre lo más difícil, fue el uso de Visual Studio Code en la parte de subir los diversos commits al repositorio. Esto lo resolví investigando como subir estos cambios sin generar ningún tipo de conflicto. Lo que haría distinto para la próxima vez es manejar de manera la herramienta de editor de código fuente para ya no tener ningún otro problema.

5. Conclusiones

1. En conclusión, clasifiqué las distintas variables existentes en los archivos que usé en la práctica con ayuda de Python tal y como se muestra en la Figura 1, dónde cliente_id, genero, nivel_educacion, ciudad son tratados como strings (str) y edad,

numero_hijos, ingresos_mensuales y satisfaccion son tratados como enteros (int64).

2. Calculé el ingreso mensual de los cuatrocientos clientes siendo 1330.72 que se la trató como el parámetro poblacional, a su vez la media estimada por conveniencia fue de 1348.50, aleatorio simple de 1336.0 y finalmente estratificado de 1287.50.
3. Finalmente, la media estimada que más se acercó fue aleatorio simple con 1336.00. Por otro lado, es importante resaltar que el diseño es el que decide, más no el tamaño de elementos y esto fue lo que sucedió con el muestreo por conveniencia ya que en el mismo, solo se ocupó datos de clientes en Quito y esto no representaba totalmente a toda la población.

Respuesta a la gerencia:

El ingreso promedio mensual de todos los clientes es de 1330.72 USD. Por otro lado, la muestra de 20 elementos puede representar prácticamente a toda la población siempre y cuando se elija un método de muestreo adecuado y dependiendo de las necesidades del caso.

Alcance:

Con una base de 400 clientes en las diferentes ciudades como Quito, Guayaquil y Cuenca en conjunto con tres modelos de muestreo de 20 elementos por lo que no se declara que un método es mejor que el otro.

6. Bibliografía

Pandas development team. (2026a). *pandas.CategoricalDtype*. https://pandas.pydata.org/docs/reference/api/pandas.CategoricalDtype.html

Pandas development team. (2026b). *pandas.DataFrame.sample*. https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.sample.html

Suárez, C. (2026). IDSD422-lab-muestreo-poblacion [Repositorio de GitHub]. GitHub. https://github.com/christian-suarez1979/IDSD422-lab-muestreo-poblacion

Declaración del uso de la IA.

En el respectivo laboratorio se usó la IA a través de Google Gemini para resolver los conflictos en cuanto a la subida de los commits al repositorio. A su vez, fue una guía para el desarrollo y la comprensión de algunas partes del código implementado.

7. Anexos

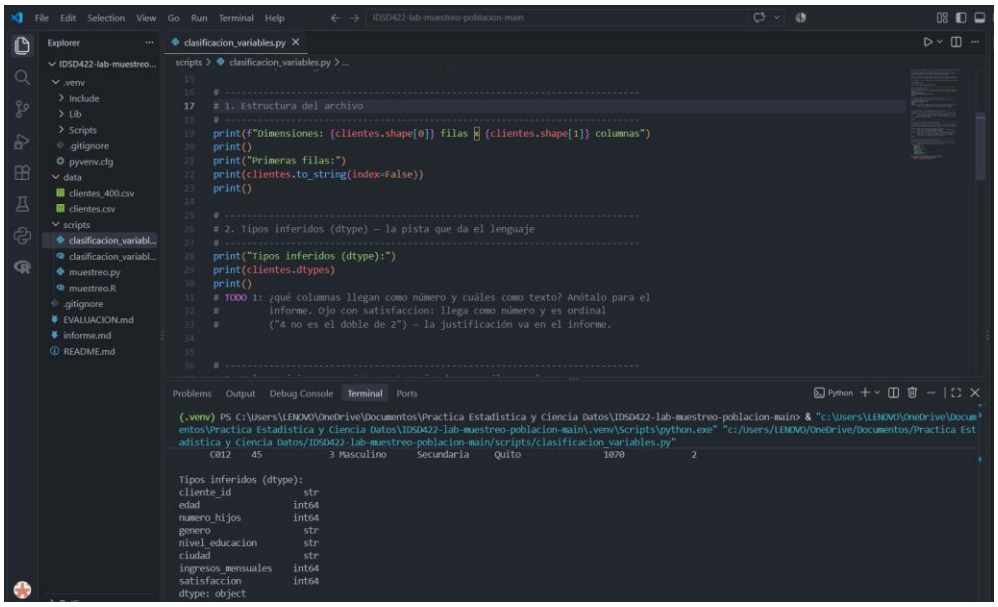


Figura 1. Ejecución del script para el análisis de los tipos de datos que existen.

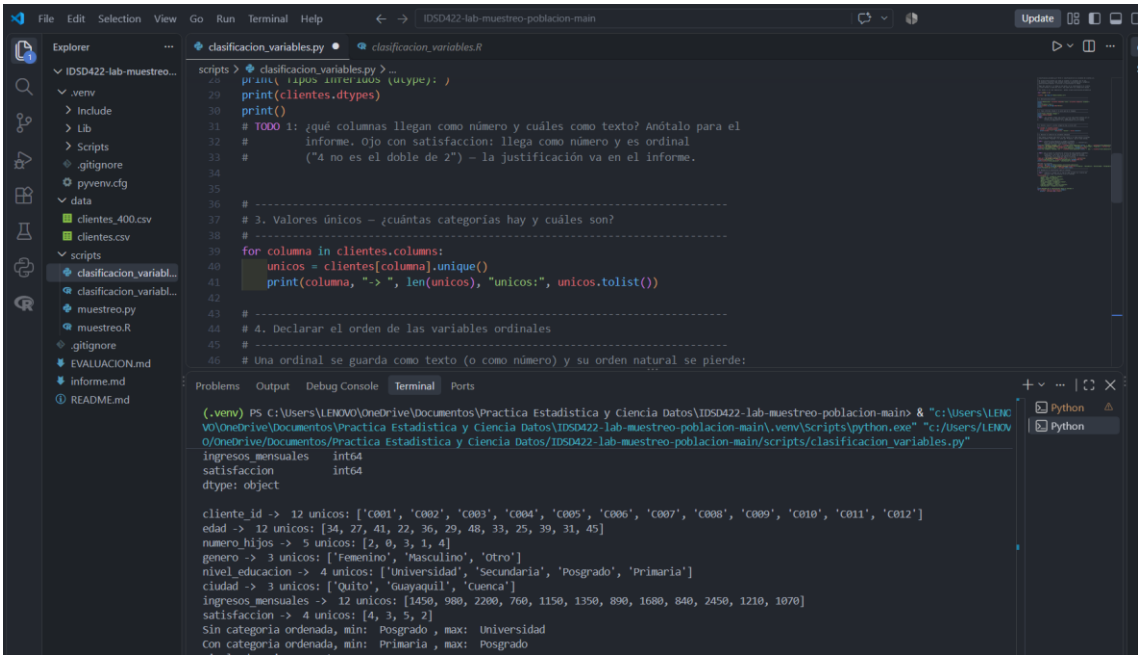


Figura 2. Indica la cantidad de categorías y cuales son.

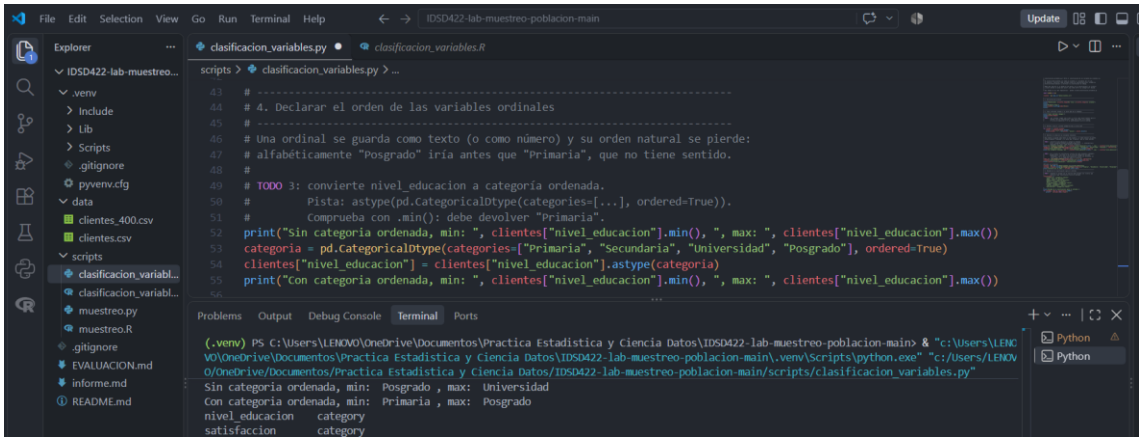


Figura 3. Orden de la variable ordinal nivel_educacion.

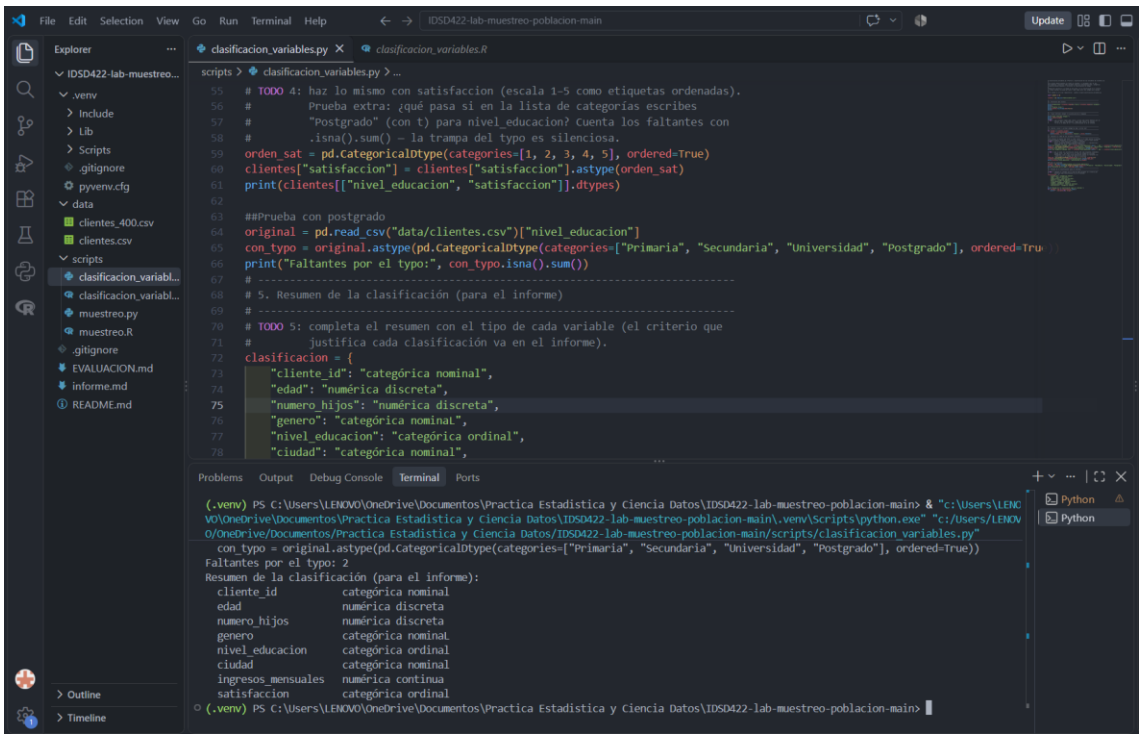


Figura 4. Orden de la variable satisfacción en conjunto con el resumen de la clasificación.

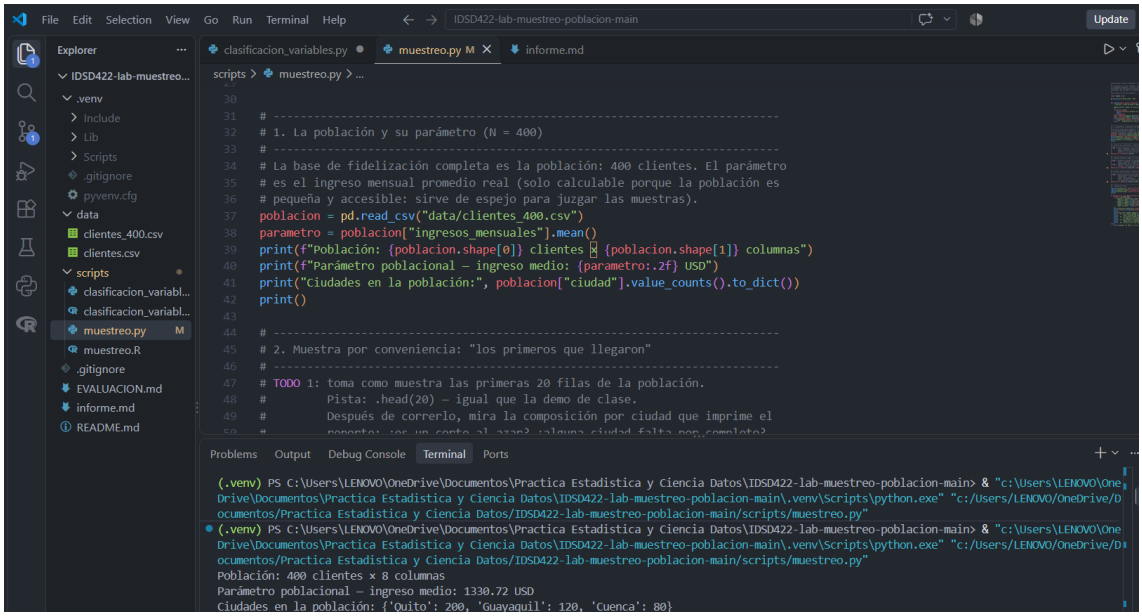


Figura 5. Indica la información de la población total en base al archivo clientes_400.csv

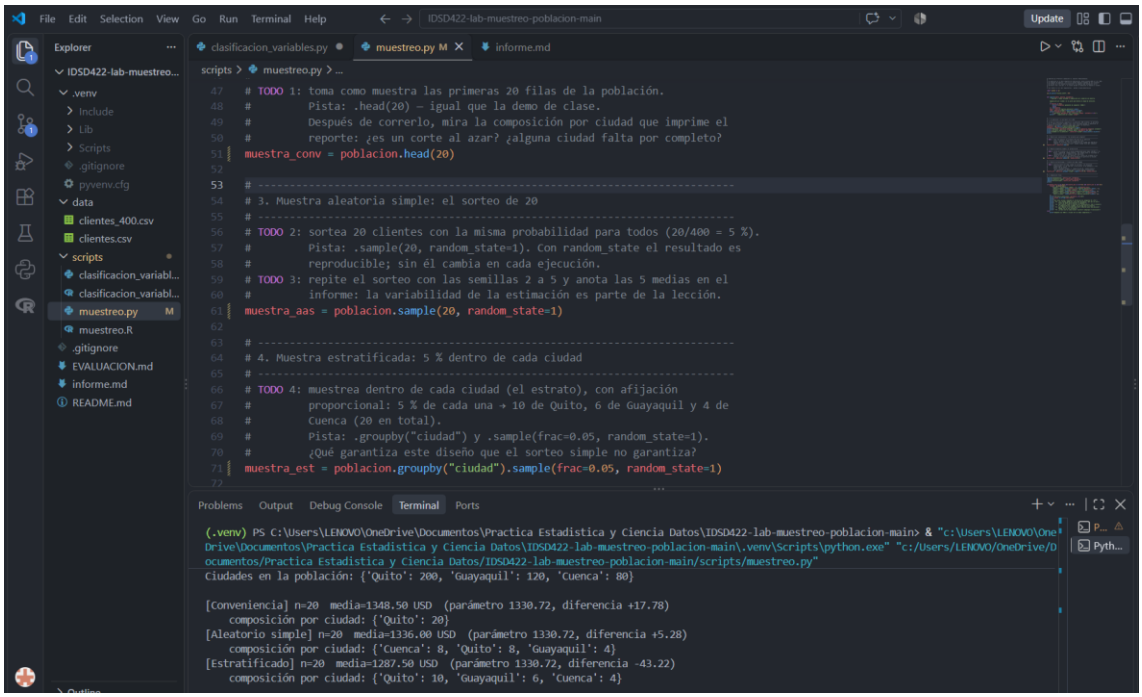


Figura 6. Métodos específicos de muestro.

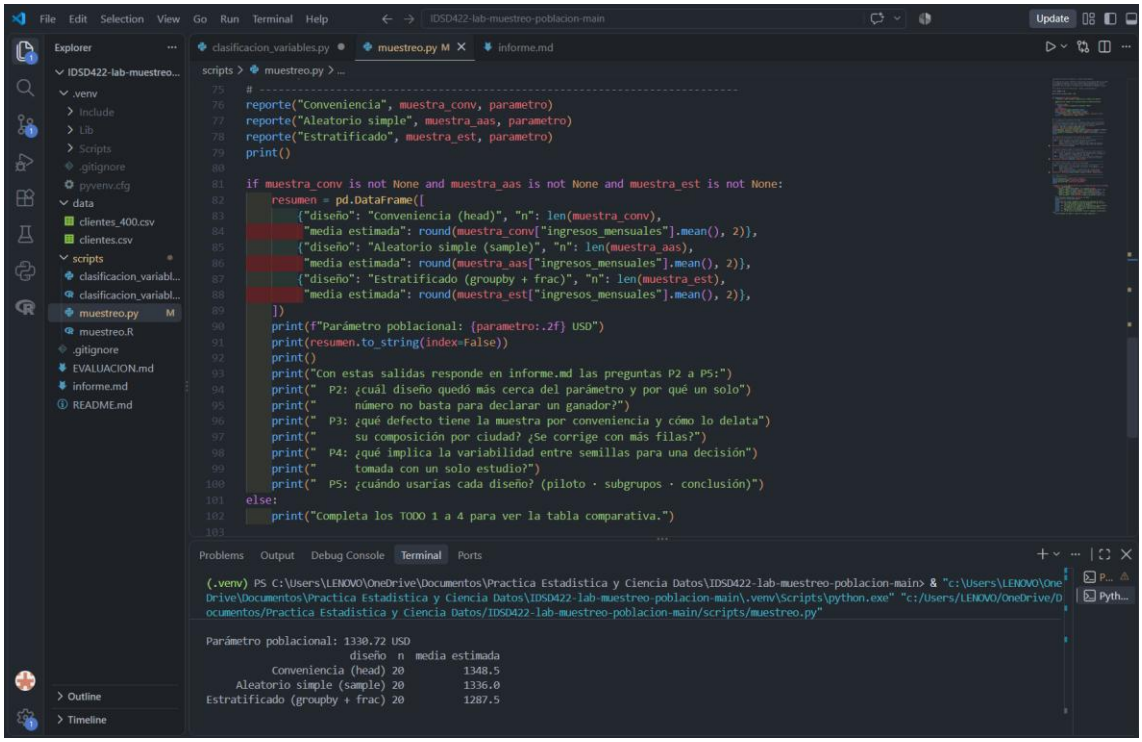


Figura 7. Cálculo del parámetro poblacional y la media estimada en cada método de muestreo.